TUGAS AKHIR

LAPORAN PROYEK DATA SCIENSE

"IMPLEMENTASI DECISION TREE UNTUK MEMPREDIKSI APAKAH NASABAH AKAN BERHUTANG ATAU TIDAK DIBANK"

IF-1 DECISION TREE

NAMA ANGGOTA:
RADITYA NALENDRA UTOMO (10122119)
MUHAMMAD ABDUL HAMID (11203462210047)

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS KOMPUTER
INDONESIA
2024

DAFTAR ISI

Daftar Isi

PENDAHULUAN 3
METEDOLOGI KDD(KNOWLEDGE DISCOVERY IN DATABASE PROCESS) 4
SELECTION 4
PREPROCESSING 4
TRANSFORMATION 4
DATA MINING 4
EVALUATION 4

Daftar Gambar

gambar 1 proses metodologi KDD
gambar 2. 1 Kolom age..... 7
gambar 2. 2 Kolom Job..... 7
gambar 2. 3 kolom marital..... 7
gambar 2. 4 kolom education 8
gambar 2. 5 kolom default..... 8
gambar 2. 6 kolom balance..... 8
gambar 2. 7 kolom housing 8
gambar 2. 8 kolom loan 9
gambar 2. 9 kolom contact 9
gambar 2. 10 kolom day 9
gambar 2. 11 kolom month..... 9
gambar 2. 12 kolom duration..... 10
gambar 2. 13 kolom campaign 10
gambar 2. 14 kolom pdays..... 10
gambar 2. 15 kolom previos 11
gambar 2. 16 kolom poutcome 11
gambar 2. 17 kolom deposit 11

PENDAHULUAN

Dalam era transformasi digital dan intensifikasi persaingan di industri perbankan, manajemen risiko kredit menjadi aspek kritis yang harus dikelola secara efektif. Salah satu tantangan utama yang dihadapi oleh lembaga keuangan adalah kemampuan untuk memprediksi perilaku nasabah, khususnya dalam konteks pembayaran kredit. Mengetahui apakah seorang nasabah akan cenderung berhutang atau tidak merupakan informasi strategis yang dapat membantu bank dalam mengelola portofolio kreditnya secara lebih cerdas.

Tingginya tingkat kompleksitas dan jumlah data yang terus meningkat menuntut penggunaan metode analisis data yang canggih untuk mendapatkan wawasan yang berharga. Salah satu pendekatan yang telah terbukti efektif adalah implementasi model Decision Tree dalam proses pengambilan keputusan kredit. Model ini mampu mengeksplorasi pola dan hubungan yang kompleks dalam data, sehingga memungkinkan bank untuk membuat keputusan yang lebih cerdas dan responsif terhadap dinamika pasar dan perilaku nasabah.Tantangan yang dihadapi oleh industri perbankan melibatkan dinamika ekonomi yang berubah-ubah, variasi perilaku nasabah yang kompleks, dan tuntutan regulasi yang semakin ketat. Dalam menghadapi tantangan ini, keberhasilan lembaga keuangan tidak hanya tergantung pada penilaian risiko yang akurat tetapi juga pada kemampuan untuk memanfaatkan teknologi dan metodologi analisis data yang canggih.

Dalam konteks ini, penelitian ini bertujuan untuk menggali potensi implementasi model Decision Tree sebagai alat prediktif yang dapat meningkatkan pemahaman bank terhadap risiko kredit. Dengan memahami pola perilaku nasabah melalui analisis data yang mendalam, bank dapat mengoptimalkan keputusan persetujuan kredit, mengurangi risiko kredit yang tidak diinginkan, dan meningkatkan kepercayaan stakeholders terkait.

METEDOLOGI KDD(KNOWLEDGE DISCOVERY IN DATABASE PROCESS)

Data mining adalah sebuah kegiatan untuk mengidentifikasi beragam jenis data. Dari banyaknya data yang tersimpan di database, data-data tersebut diidentifikasi baik dicari kemungkinan adanya pola ataupun lainnya yang dianggap berpotensi untuk menghasilkan sesuatu yang bisa dipakai oleh organisasi atau perusahaan yang memiliki database tersebut. Data mining itu sendiri meiliki beragam metode yang bisa digunakan yaitu KDD, CRISP-DM, SEMMA, dll. Setiap proses memiliki metode yang berbeda-beda dalam pencarian informasi penting yang ada di dalam database orgnisasi. Pada artikel ini kita akan membahas KDD atau Knowledge Discovery in Database Process.

Knowledge Discovery in Database Process (KDD) adalah salah satu metode yang bisa digunakan dalam melakukan data mining. Fayyed et al. (1996) mendefinisikan KDD sebagai proses dari menggunakan metode data mining untuk mencari informasi-informasi yang berharga, pola yang ada di dalam data, yang melibatkan algoritma untuk mengidentifikasi pola pada data. Dunham (2003) meringkas proses KDD dari berbagai step, yaitu: seleksi data, pra-proses data, transformasi data, data mining, dan yang terakhir interpretasi dan evaluasi. Berikut adalah ilustrasi serta penjelasan menegenai proses KDD secara detail:

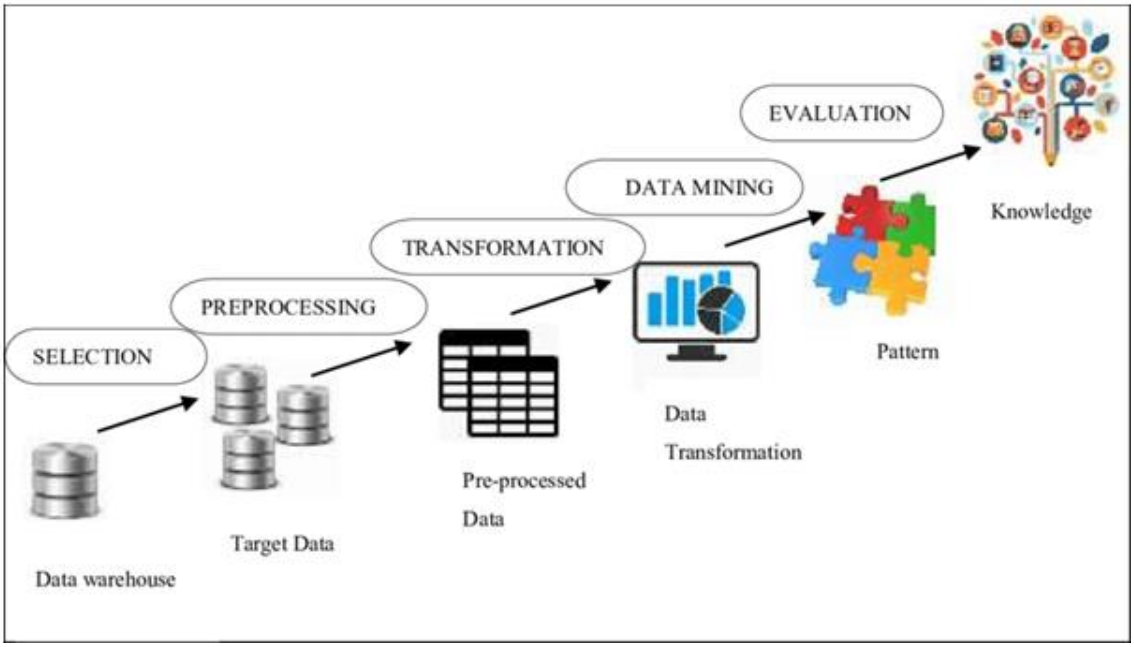

gambar 1 proses metodologi KDD

SELECTION

Pada tahap awal, kami menggunakan dataset bank yang diambil dari Kaggle (https://www.kaggle.com/datasets/janiobachmann/bank-marketing-dataset). Dataset ini terdiri dari 11162 data dengan 17 kolom yang mencakup berbagai informasi terkait nasabah dan keputusan mereka untuk berlangganan produk bank. Pemilihan dataset ini didasarkan pada tujuan untuk memprediksi apakah nasabah akan berhutang atau tidak di bank..

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 11162 entries, 0 to 11161
Data columns (total 17 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   age         11162 non-null  int64
 1   job         11162 non-null  object
 2   marital     11162 non-null  object
 3   education   11162 non-null  object
 4   default     11162 non-null  object
 5   balance     11162 non-null  int64
 6   housing     11162 non-null  object
 7   loan        11162 non-null  object
 8   contact     11162 non-null  object
 9   day         11162 non-null  int64
 10  month       11162 non-null  object
 11  duration    11162 non-null  int64
 12  campaign    11162 non-null  int64
 13  pdays       11162 non-null  int64
 14  previous    11162 non-null  int64
 15  poutcome    11162 non-null  object
 16  deposit     11162 non-null  object
dtypes: int64(7), object(10)
memory usage: 1.4+ MB
```

gambar 2 Data set Info

Dengan keterangan tiap kolom sebagai berikut

- Age (umur)
  Merupakan Kolom pertama pada dataset terdiri dari 24 variabel yaitu

```
Data  age:
count    11162.000000
mean        41.231948
std         11.913369
min         18.000000
25%         32.000000
50%         39.000000
75%         49.000000
max         95.000000
Name: age, dtype: float64

Variabel dalam kolom age:
[59 56 41 55 54 42 60 37 28 38 30 29 46 31 35 32 49 43 26 40 33 23 48 45
 36 52 53 39 57 51 44 24 50 27 34 47 25 58 61 68 75 22 69 66 85 72 90 67
 71 21 74 65 62 83 70 76 77 19 73 63 20 78 95 64 79 82 18 86 84 87 92 81
 80 93 88 89]
```

gambar 2. 1 Kolom age

- Job
  Merupakan Kolom pekerjaan apa saja pada nasabah bank

```
Data  job:
count          11162
unique            12
top       management
freq            2566
Name: job, dtype: object
```

gambar 2. 2 Kolom Job

- Marital
  Merupakan apakah nasabah sudah menikah atau belum

```
Data  marital:
count       11162
unique          3
top       married
freq         6351
Name: marital, dtype: object
```

gambar 2. 3 kolom marital

- Education
  Merupakan data Pendidikan nasabah bank

```
Data  education:
count         11162
unique            4
top       secondary
freq           5476
Name: education, dtype: object
```

gambar 2. 4 kolom education

- Default

```
Data  default:
count     11162
unique        2
top          no
freq      10994
Name: default, dtype: object
```

gambar 2. 5 kolom default

- Data Balance

```
Data  default:
count     11162
unique        2
top          no
freq      10994
Name: default, dtype: object
```

gambar 2. 6 kolom balance

- Data Housing

```
Data  housing:
count     11162
unique        2
top          no
freq       5881
Name: housing, dtype: object
```

gambar 2. 7 kolom housing

- Data Loan

```
Data  loan:
count     11162
unique        2
top          no
freq       9702
Name: loan, dtype: object
```

gambar 2. 8 kolom loan

- Data Contact

```
Data  contact:
count        11162
unique           3
top       cellular
freq          8042
Name: contact, dtype: object
```

gambar 2. 9 kolom contact

- Data Day

```
Data  day:
count    11162.000000
mean        15.658036
std          8.420740
min          1.000000
25%          8.000000
50%         15.000000
75%         22.000000
max         31.000000
Name: day, dtype: float64
```

gambar 2. 10 kolom day

- Data Month

```
Data  month:
count     11162
unique       12
top         may
freq       2824
Name: month, dtype: object
```

gambar 2. 11 kolom month

- Data duration

```
Data  duration:
count    11162.000000
mean       371.993818
std        347.128386
min          2.000000
25%        138.000000
50%        255.000000
75%        496.000000
max       3881.000000
Name: duration, dtype: float64
```

gambar 2. 12 kolom duration

- Data Campaign

```
Data  campaign:
count    11162.000000
mean         2.508421
std          2.722077
min          1.000000
25%          1.000000
50%          2.000000
75%          3.000000
max         63.000000
Name: campaign, dtype: float64
```

gambar 2. 13 kolom campaign

- Data pdays

```
Data  pdays:
count    11162.000000
mean        51.330407
std        108.758282
min         -1.000000
25%         -1.000000
50%         -1.000000
75%         20.750000
max        854.000000
Name: pdays, dtype: float64
```

gambar 2. 14 kolom pdays

- Data previos

```
Data  previous:
count    11162.000000
mean         0.832557
std          2.292007
min          0.000000
25%          0.000000
50%          0.000000
75%          1.000000
max         58.000000
Name: previous, dtype: float64
```

gambar 2. 15 kolom previos

- Data Poutcome

```
Data  poutcome:
count       11162
unique          4
top       unknown
freq         8326
Name: poutcome, dtype: object
```

gambar 2. 16 kolom poutcome

- Data Deposit

```
Data  deposit:
count     11162
unique        2
top          no
freq       5873
Name: deposit, dtype: object
```

gambar 2. 17 kolom deposit

PREPROCESSING

Setelah dataset dipilih, tahap berikutnya adalah preprocessing data. Langkah pertama adalah mengubah data kategorikal menjadi data numerik agar dapat diolah oleh algoritma machine learning. Kami juga melakukan penghapusan kolom yang tidak relevan atau tidak diperlukan untuk analisis prediksi perilaku nasabah. Selanjutnya, kami melakukan pembagian umur nasabah menjadi kategori seperti child, teenager, adult, dan elderly. Hal ini bertujuan untuk merubah representasi umur menjadi bentuk yang lebih sesuai dengan karakteristik data.

```
#preprocessing mengubah data job menjadi numerik
df["job"].replace({
  'unknown': np.nan,
  'management': 0,
  'technician': 1,
  'entrepreneur': 2,
  'blue-collar': 3,
  'retired': 4,
  'admin.': 5,
  'services': 6,
  'self-employed': 7,
  'unemployed': 8,
  'housemaid': 9,
  'student': 10
}, inplace=True)
```

```
df.head()
```

gambar 3.1 preprocessing megubah data job menjadi numerik

- Data Marital menjadi numerik

```python
#preprocessing mengubah data marital menjadi numerik
def replace_marital (val):
  if val == "single":
    return 0
  else:
    return 1
df["marital"] = df["marital"].apply(replace_marital, 1)
```

```python
df.head()
```

	age	job	marital	education	default	balance	housing	loan
890	42	5.0	0	1.0	0	0.074957	1	1
891	33	6.0	1	1.0	0	0.116875	1	0
951	53	4.0	1	0.0	0	0.103531	0	0
952	37	1.0	1	1.0	0	0.135853	1	0
953	45	2.0	1	1.0	0	0.086632	0	1

gambar 3.2 mengubah data marital menjadi numerik

- Data Housing Menjadi Numerik

```python
#preprocessing mengubah data housing menjadi numerik
df["housing"] = df["housing"].map({
  "no": 0,
  "yes": 1
}.get)
```

```python
df.head()
```

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	deposit
0	59	admin.	married	secondary	no	2343	yes	no	unknown	5	may	1042	1	-1	0	unknown	yes
1	56	admin.	married	secondary	no	45	no	no	unknown	5	may	1467	1	-1	0	unknown	yes
2	41	technician	married	secondary	no	1270	yes	no	unknown	5	may	1389	1	-1	0	unknown	yes
3	55	services	married	secondary	no	2476	yes	no	unknown	5	may	579	1	-1	0	unknown	yes
4	54	admin.	married	tertiary	no	184	no	no	unknown	5	may	673	2	-1	0	unknown	yes

gambar 3.3 mengubah data housing menjad numerik

- data loan menjadi numerik

```
#preprocessing mengubah data loan menjadi numerik
df["loan"] = df["loan"].replace({
"no": 0 ,
"yes": 1
})
```

```
df.head()
```

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	deposit
0	59	5.0	1	secondary	no	2343	1	0	unknown	5	may	1042	1	-1	0	unknown	yes
1	56	5.0	1	secondary	no	45	0	0	unknown	5	may	1467	1	-1	0	unknown	yes
2	41	1.0	1	secondary	no	1270	1	0	unknown	5	may	1389	1	-1	0	unknown	yes
3	55	6.0	1	secondary	no	2476	1	0	unknown	5	may	579	1	-1	0	unknown	yes
4	54	5.0	1	tertiary	no	184	0	0	unknown	5	may	673	2	-1	0	unknown	yes

gambar 3.4 mengubah data loan menjadi numerik

- Mengubah data education ke numerik

```
#preprocessing mengubah data education menjadi numerik
df ["education"].replace({
  'unknown': np.nan,
  'tertiary': 0,
  'secondary': 1,
  'primary': 2
}, inplace=True)
```

```
df.head()
```

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	deposit
0	59	5.0	1	1.0	no	2343	1	0	unknown	5	may	1042	1	-1	0	unknown	yes
1	56	5.0	1	1.0	no	45	0	0	unknown	5	may	1467	1	-1	0	unknown	yes
2	41	1.0	1	1.0	no	1270	1	0	unknown	5	may	1389	1	-1	0	unknown	yes
3	55	6.0	1	1.0	no	2476	1	0	unknown	5	may	579	1	-1	0	unknown	yes
4	54	5.0	1	0.0	no	184	0	0	unknown	5	may	673	2	-1	0	unknown	yes

gambar 3.5 mengubah data education menjadi numerik

- Mengubah data default menjadi numerik

```
#preprocessing mengubah data default menjadi numerik
df["default"].replace(
  { "no": 0,
    "yes": 1
  }, inplace=True)
```

```
df.head()
```

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	deposit
0	59	5.0	1	1.0	0	2343	1	0	unknown	5	may	1042	1	-1	0	unknown	yes
1	56	5.0	1	1.0	0	45	0	0	unknown	5	may	1467	1	-1	0	unknown	yes
2	41	1.0	1	1.0	0	1270	1	0	unknown	5	may	1389	1	-1	0	unknown	yes
3	55	6.0	1	1.0	0	2476	1	0	unknown	5	may	579	1	-1	0	unknown	yes
4	54	5.0	1	0.0	0	184	0	0	unknown	5	may	673	2	-1	0	unknown	yes

gambar 3.6 mengubah data default menjadi numerik

- menampilkan balance terkecil dan terkecil serta menormalisasi kolom balance

```
#menampilkan balance terkecil
df ['balance'].min()
```

```
-6847
```

```
#menampilkan balance terbesar
df ['balance'].max()
```

```
81204
```

```
#preprocessing menormalisasi kolom balance
df["balance"] = df ["balance"].apply(lambda v: (v - df["balance"].min()) / (df["balance"].max()-df["balance"].min()))
```

```
df.head()
```

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	deposit
0	59	admin.	married	1.0	0	0.104371	yes	0	unknown	5	may	1042	1	-1	0	unknown	yes
1	56	admin.	married	1.0	0	0.078273	no	0	unknown	5	may	1467	1	-1	0	unknown	yes
2	41	technician	married	1.0	0	0.092185	yes	0	unknown	5	may	1389	1	-1	0	unknown	yes
3	55	services	married	1.0	0	0.105882	yes	0	unknown	5	may	579	1	-1	0	unknown	yes
4	54	admin.	married	0.0	0	0.079851	no	0	unknown	5	may	673	2	-1	0	unknown	yes

gambar 3 7 balance terkecil dan terbesar

- Mengubah data Contact menjadi Numerik

```
#preprocessing mengubah data contact menjadi numerik
df.contact.replace({
    "unknown": np.nan,
    "telephone": 0,
    "cellular": 1
  }, inplace=True)
```

```
df.head()
```

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	deposit
0	59	5.0	1	1.0	0	0.104371	1	0	NaN	5	may	1042	1	-1	0	unknown	yes
1	56	5.0	1	1.0	0	0.078273	0	0	NaN	5	may	1467	1	-1	0	unknown	yes
2	41	1.0	1	1.0	0	0.092185	1	0	NaN	5	may	1389	1	-1	0	unknown	yes
3	55	6.0	1	1.0	0	0.105882	1	0	NaN	5	may	579	1	-1	0	unknown	yes
4	54	5.0	1	0.0	0	0.079851	0	0	NaN	5	may	673	2	-1	0	unknown	yes

gambar 3.8 mengubah data contact menjadi numeri

- data month menjadi numerik

```
#preprocessing mengubah data month menjadi numerik
df.month = df.month.map({
'oct': 10, 'may': 5, 'apr': 4, 'jun': 6, 'feb': 2, 'aug': 8, 'jan': 1, 'jul': 7, 'nov': 11,
'sep': 9, 'mar': 3, 'dec': 12
})
```

```
df.head()
```

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	deposit
0	59	5.0	1	1.0	0	0.104371	1	0	NaN	5	5	1042	1	-1	0	unknown	yes
1	56	5.0	1	1.0	0	0.078273	0	0	NaN	5	5	1467	1	-1	0	unknown	yes
2	41	1.0	1	1.0	0	0.092185	1	0	NaN	5	5	1389	1	-1	0	unknown	yes
3	55	6.0	1	1.0	0	0.105882	1	0	NaN	5	5	579	1	-1	0	unknown	yes
4	54	5.0	1	0.0	0	0.079851	0	0	NaN	5	5	673	2	-1	0	unknown	yes

gambar 3 9 mengubah data month menjadi numerik

- data pdays menjadi numerik

```
#preprocessing menormalisasi data pdays
df.pdays= df.pdays.apply(lambda v: (v-df.pdays.min())/(df.pdays.max()-df.pdays.min()))
```

```
df.head()
```

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	deposit
0	59	5.0	1	1.0	0	0.104371	1	0	NaN	5	5	1042	1	-1	0	NaN	yes
1	56	5.0	1	1.0	0	0.078273	0	0	NaN	5	5	1467	1	-1	0	NaN	yes
2	41	1.0	1	1.0	0	0.092185	1	0	NaN	5	5	1389	1	-1	0	NaN	yes
3	55	6.0	1	1.0	0	0.105882	1	0	NaN	5	5	579	1	-1	0	NaN	yes
4	54	5.0	1	0.0	0	0.079851	0	0	NaN	5	5	673	2	-1	0	NaN	yes

gambar 3.10 mengubah data pdays menjadi numerik

- data deposit menjadi numerik

```
#preprocessing mengubah data deposit menjadi numerik
df.deposit.replace({"no": 0, "yes": 1}, inplace=True)
```

```
df.head()
```

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	deposit
0	59	5.0	1	1.0	0	0.104371	1	0	NaN	5	5	1042	1	0.0	0	NaN	1
1	56	5.0	1	1.0	0	0.078273	0	0	NaN	5	5	1467	1	0.0	0	NaN	1
2	41	1.0	1	1.0	0	0.092185	1	0	NaN	5	5	1389	1	0.0	0	NaN	1
3	55	6.0	1	1.0	0	0.105882	1	0	NaN	5	5	579	1	0.0	0	NaN	1
4	54	5.0	1	0.0	0	0.079851	0	0	NaN	5	5	673	2	0.0	0	NaN	1

gambar 3 11 menguba data duration menjadi numerik

- normalisasi data duration

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	deposit
0	59	5.0	1	1.0	0	0.104371	1	0	NaN	5	5	0.268110	1	0.0	0	NaN	1
1	56	5.0	1	1.0	0	0.078273	0	0	NaN	5	5	0.377675	1	0.0	0	NaN	1
2	41	1.0	1	1.0	0	0.092185	1	0	NaN	5	5	0.357566	1	0.0	0	NaN	1
3	55	6.0	1	1.0	0	0.105882	1	0	NaN	5	5	0.148750	1	0.0	0	NaN	1
4	54	5.0	1	0.0	0	0.079851	0	0	NaN	5	5	0.172983	2	0.0	0	NaN	1

gambar 3 12 normalisasi data duration

- hasil preprocesing

```
    age  job  marital  education  default   balance  housing  loan  contact  \
0    59  5.0        1        1.0        0  0.104371        1     0      NaN
1    56  5.0        1        1.0        0  0.078273        0     0      NaN
2    41  1.0        1        1.0        0  0.092185        1     0      NaN
3    55  6.0        1        1.0        0  0.105882        1     0      NaN
4    54  5.0        1        0.0        0  0.079851        0     0      NaN

    day  month  duration  campaign  pdays  previous  poutcome  deposit
0     5      5  0.268110         1    0.0         0       NaN        1
1     5      5  0.377675         1    0.0         0       NaN        1
2     5      5  0.357566         1    0.0         0       NaN        1
3     5      5  0.148750         1    0.0         0       NaN        1
4     5      5  0.172983         2    0.0         0       NaN        1
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 11162 entries, 0 to 11161
Data columns (total 17 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   age        11162 non-null  int64
 1   job        11092 non-null  float64
 2   marital    11162 non-null  int64
 3   education  10665 non-null  float64
 4   default    11162 non-null  int64
 5   balance    11162 non-null  float64
 6   housing    11162 non-null  int64
 7   loan       11162 non-null  int64
 8   contact    8816 non-null   float64
 9   day        11162 non-null  int64
 10  month      11162 non-null  int64
 11  duration   11162 non-null  float64
 12  campaign   11162 non-null  int64
 13  pdays      11162 non-null  float64
 14  previous   11162 non-null  int64
 15  poutcome   2836 non-null   float64
 16  deposit    11162 non-null  int64
dtypes: float64(7), int64(10)
memory usage: 1.4 MB
```

gambar 3.13 hasil preprocesing

None

	age	job	marital	education	default
count	11162.000000	11092.000000	11162.000000	10665.000000	11162.000000
mean	41.231948	3.190408	0.684824	0.794749	0.015051
std	11.913369	2.811062	0.464607	0.666677	0.121761
min	18.000000	0.000000	0.000000	0.000000	0.000000
25%	32.000000	1.000000	0.000000	0.000000	0.000000
50%	39.000000	3.000000	1.000000	1.000000	0.000000
75%	49.000000	5.000000	1.000000	1.000000	0.000000
max	95.000000	10.000000	1.000000	2.000000	1.000000

	balance	housing	loan	contact	day \
count	11162.000000	11162.000000	11162.000000	8816.000000	11162.000000
mean	0.095121	0.473123	0.130801	0.912205	15.658036
std	0.036631	0.499299	0.337198	0.283012	8.420740
min	0.000000	0.000000	0.000000	0.000000	1.000000
25%	0.079147	0.000000	0.000000	1.000000	8.000000
50%	0.084008	0.000000	0.000000	1.000000	15.000000
75%	0.097160	1.000000	0.000000	1.000000	22.000000
max	1.000000	1.000000	1.000000	1.000000	31.000000

	month	duration	campaign	pdays	previous \
count	11162.000000	11162.000000	11162.000000	11162.000000	11162.000000
mean	6.190826	0.095384	2.508421	0.061205	0.832557
std	2.572792	0.089489	2.722077	0.127203	2.292007
min	1.000000	0.000000	1.000000	0.000000	0.000000
25%	5.000000	0.035061	1.000000	0.000000	0.000000
50%	6.000000	0.065223	2.000000	0.000000	0.000000
75%	8.000000	0.127352	3.000000	0.025439	1.000000
max	12.000000	1.000000	63.000000	1.000000	58.000000

	poutcome	deposit
count	2836.000000	11162.000000
mean	0.944640	0.473840
std	0.898815	0.499338
min	0.000000	0.000000
25%	0.000000	0.000000
50%	1.000000	0.000000
75%	2.000000	1.000000
max	2.000000	1.000000

TRANSFORMATION

Setelah itu proses transformasi yang bertujuan untuk mendapatkan representasi dokumen sesuai dengan yang diharapkan. Pada tahapan ini kami dengan cara menghapus kolom yang tidak dinginkan karena menurut kami untuk melakukan prediksi tidak perlu semua kolom dipakai.

```
#transformasi data dengan cara menghapus kolom yang tidak di perluka
df.drop(['balance','contact', 'day',  'month',
         'duration',  'campaign', 'pdays',  'previous',
         'poutcome',  'deposit'], axis=1, inplace=True)
```

gambar 4 1 transformasi data dengan cara menghapus data yang tidak diperlukan

setelah itu kami merubah age menjadi beberapa bagian yaitu ketika dibawah 13 tahun child, jika dibawah 19 tahun diatas 13 tahun teenager, jika dibawah 60 tahun diatas 19 tahun maka adult, dab ketika diatas 60 tahun menjadi ederly.

```
def new_age(x):
    if x < 13:
        return 'child'
    elif 12 < x <= 19:
        return 'teenager'
    elif 19 < x <= 60:
        return 'adult'
    elif x > 60:
        return 'elderly'

# Menggantikan nilai pada kolom "age" dengan hasil dari fungsi new_age
df2["age"] = df2["age"].apply(new_age)
```

gambar 4 2 transformasi data

dan yang terakhir kami mengubah variabel yang awalnya child, teenager, adult, dan erdely menjadi numerika tapi dari 0,1,2,dan 3

```
df2.age = df2.age.map({
  'unknown': np.nan,
  'child': 0,
  'teenager': 1,
  'adult': 2,
  'elderly' : 3
})

display(df2)
```

gambar 4 3 transformasi data age

DATA MINING

Dari berbagai model klasifikasi yang ada digunakan model Decision Tree, yaitu dengan menggunakan algoritma Iterative Dichotomiser 3 (ID3) merupakan sebuah metode yang digunakan Decision untuk Tree yang membangkitkan mendapatkan informasi berdasarkan entropy yang merupakan sistem pengukuran statistik.

Sample data yang digunakan oleh ID3 memiliki beberapa syarat, yaitua tribut yang sama harus mendeskripsikan tiap contoh dan memiliki jumlah nilai yang sudah ditentukan. Pemillihan atribut pada ID3 dilakukan dengan properti statistik, yang disebut dengan information gain. Gain mengukur seberapa baik suatu atribut memisahkan training example ke dalam kelas target. Atribut dengan informasi tertinggi akan dipilih. Dengan tujuan untuk mendefinisikan gain, pertama-tama digunakanlah ide dari teori informasi yang disebut entropi. Entropi mengukur jumlah informasi yang ada pada atribut.

Rumus entropi adalah:

$$Entropy(S) = -\sum p \log_2 p$$

Rumus untuk menghitung gain adalah:

Setelah mendapatkan informasi dari semua atribut yang dihitung, atribut dengan information gain tertinggi dipilih sebagai atribut node awal (root node) serta cabang-cabangnya di buat sesaui nilai-nilai kemungkinan. Proses ini terus berulang sepanjang/ pada setiap cabang

$$Gain(S, A) = Entropy(S) - \sum_{a \varepsilon A} \frac{|S_a|}{|S|} Entropy(S_a)$$

Setelah mendapatkan informasi dari semua atribut yang dihitung, atribut dengan information gain tertinggi dipilih sebagai atribut node awal (root node) serta cabang-cabangnya di buat sesaui nilai-nilai kemungkinan. Proses ini terus berulang sepanjang/ pada setiap cabang.

Pada tahap selanjutnya yaitu penerapan algoritma Desesion Tree (D3)pada dataset yang telah diproses pada tahap sebelumnya. disini kami membuat decession tree dengan model DecisonTreeClassifier

```
#membuat decission tree atau pohon keputusan

file = ('data_bank_bersih.csv')
df3 = pd.read_csv(file)

from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier, export_text

X = df3.drop('loan', axis=1)
y = df3['loan']

# Pisahkan data menjadi data latih dan data uji
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Buat model Decision Tree
model = DecisionTreeClassifier(criterion='entropy')

# Latih model dengan data latih
model.fit(X_train, y_train)
```

memvisualisasikan pohon keputusan secara grafis, memudahkan interpretasi aturan keputusan dan melihat struktur pohon secara keseluruhan.

EVALUATION

Setelah penerapan algoritma pada dataset kemudian kami membandingkan nilai hasil dan akurasi setelah itu didapatkan nilai akurasi dari setiap metode algoritma yang digunakan. Hasil dari penerapan metode algoritma desesion tree dapat dilihat pada Gambar dibawah

```
# Evaluasi model pada data uji
accuracy = model.score(X_test, y_test)
print(f'Akurasi Model: {accuracy:.2f}')

# Tampilkan decision tree
tree_rules = export_text(model, feature_names=X.columns.tolist())
print("Decision Tree Rules:\n", tree_rules)
```

```
Akurasi Model: 0.93
Decision Tree Rules:
 |--- housing <= 0.50
|   |--- education <= 0.50
|   |   |--- job <= 6.00
|   |   |   |--- job <= 4.50
|   |   |   |   |--- marital <= 0.50
|   |   |   |   |   |--- class: 0
|   |   |   |   |--- marital >  0.50
|   |   |   |   |   |--- job <= 0.50
|   |   |   |   |   |   |--- age <= 2.50
|   |   |   |   |   |   |   |--- class: 0
|   |   |   |   |   |   |--- age >  2.50
|   |   |   |   |   |   |   |--- class: 0
|   |   |   |   |   |--- job >  0.50
|   |   |   |   |   |   |--- class: 0
|   |   |   |--- job >  4.50
|   |   |   |   |--- marital <= 0.50
|   |   |   |   |   |--- class: 0
|   |   |   |   |--- marital >  0.50
|   |   |   |   |   |--- class: 0
```

Hasil penerapan metode Desesion Tree mendapatkan akurasi sebesar 93.10% dengan mengambil 1000 data dengan posisi housing yang menjadi variabel utama.

selanjutnya kami melakukan perbandingan dengan mengambil 30 sampel data dan yang terjadi job menjadi bagian variabel utamanya dengan akurasi sebesar 94% seperti gambar dibawah ini

```python
# Evaluasi model pada data uji
scores = cross_val_score(model, X_train, y_train, cv=5)
print(f'Akurasi Model: {accuracy:.2f}')

# Tampilkan decision tree
tree_rules = export_text(model, feature_names=X.columns.tolist())
print("Decision Tree Rules:\n", tree_rules)
```

```
Akurasi Model: 0.94
Decision Tree Rules:
 |--- job <= 0.50
|   |--- class: 0
|--- job >  0.50
|   |--- job <= 5.50
|   |   |--- education <= 1.50
|   |   |   |--- housing <= 0.50
|   |   |   |   |--- education <= 0.50
|   |   |   |   |   |--- class: 0
|   |   |   |   |--- education >  0.50
|   |   |   |   |   |--- job <= 1.50
|   |   |   |   |   |   |--- class: 0
|   |   |   |   |   |--- job >  1.50
|   |   |   |   |   |   |--- class: 1
|   |   |   |--- housing >  0.50
```

Setelah didapatkan kedua hasil dari metode yang telah diterapkan kami menggunakan salah satu metode Desesion Tree dengan tingkat akurasi tertinggi yang akan digunakan pada dataset yaitu dengan mengambil 30 data. Kemudian metode ini akan digunakan dalam proses prediksi nasabah berhutang atau tidak.

Akurasi model Decision Tree dievaluasi menggunakan beberapa metrik evaluasi, seperti akurasi, presisi, recall, dan F1-score. Kami membandingkan hasil evaluasi dari dua skenario: pengambilan 1000 sampel data dengan housing sebagai variabel utama dan pengambilan 30 sampel data dengan job sebagai variabel utama. Hal ini bertujuan untuk memilih skenario dengan tingkat akurasi tertinggi yang sesuai dengan karakteristik dataset.

KNOWLEDGE

Hasil dari penerapan Decision Tree dievaluasi melalui visualisasi pohon keputusan. Visualisasi ini memberikan gambaran secara grafis tentang aturan keputusan yang dihasilkan oleh model. Pohon keputusan memungkinkan interpretasi yang lebih mudah terhadap faktor-faktor yang mempengaruhi prediksi perilaku nasabah.

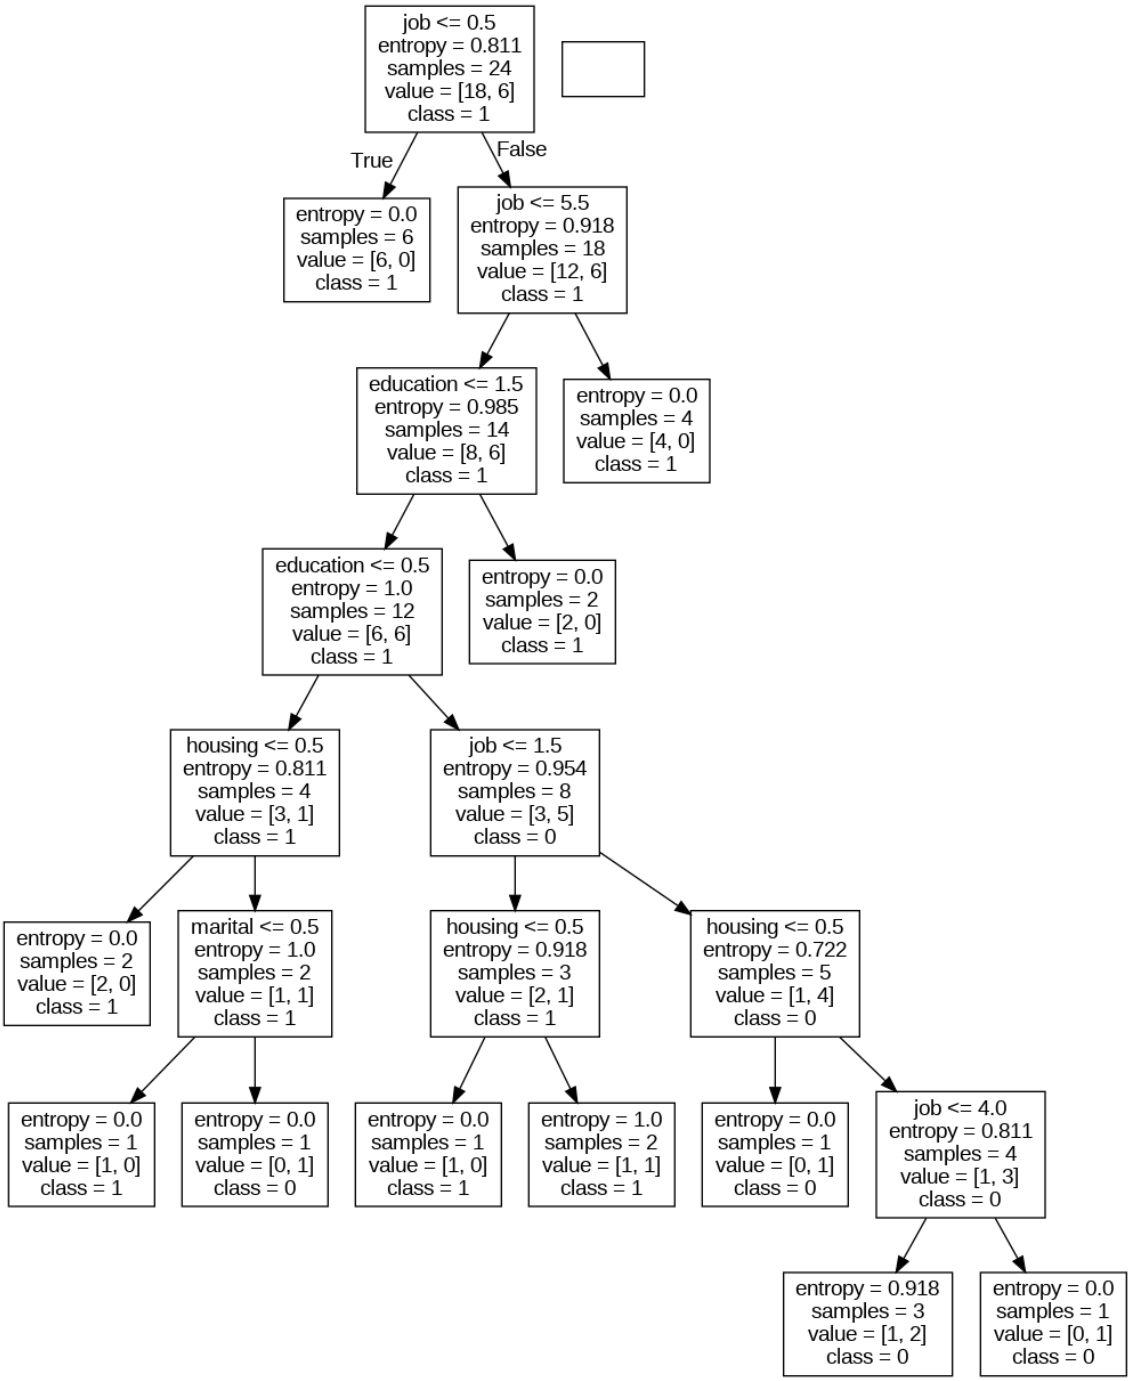

Dalam evaluasi akurasi metode Decision Tree, kami mengamati hasil pengujian dengan mengambil 1000 sampel data dan 30 sampel data. Pada pengambilan 1000 sampel data, variabel utama adalah housing, dan pada pengujian dengan 30 sampel, variabel utama adalah job.

Pengujian dengan 1000 Sampel Data (housing sebagai variabel utama)

Hasil evaluasi menunjukkan bahwa model Decision Tree memiliki akurasi sebesar 93.10%. Model ini mampu dengan baik dalam memprediksi apakah nasabah akan berhutang atau tidak berdasarkan variabel housing. Analisis lebih lanjut dilakukan terhadap faktor-faktor yang paling berpengaruh pada keputusan prediksi.

	age	job	marital	education	default	housing
0	2	1	0	1	1	1
1	1	2	1	0	0	0

```
Hasil Prediksi untuk Data Baru:
[0 0]
```

Pengujian dengan 30 Sampel Data (job sebagai variabel utama)

Kami juga melakukan pengujian dengan mengambil 30 sampel data dengan variabel utama job. Pada pengujian ini, model Decision Tree mencapai akurasi sebesar 94%. Variabel job memiliki pengaruh yang signifikan dalam memprediksi perilaku nasabah.

	age	job	marital	education	default	housing
0	2	1	0	1	1	1
1	1	2	1	0	0	0

```
Hasil Prediksi untuk Data Baru:
[0 0]
```